

Nimbus Growth Desk

일주일의 결정을 점심 전에

SEG-0000214 발견 → 근거 검색 → AI 초안 → 사람 승인 → Lakebase 반영 → Gateway 비용 확인

30분 세션

본편 8분 · 라이브 10분 · 마무리 4분 · Q&A 8분

2026.08.27 · Seoul

매주 늦어질 때 전환이 사라집니다

회사 전체 임팩트와 단일 세그먼트 임팩트를 섞지 않고 각각 계산합니다.

연간 온라인 매출

\$400M

회사 전체 기준

전환율 1%p의 연간 가치

\$4M

$\$400M \times 1\%p \cdot \text{회사 전체}$

월간 활성 사용자

15M

Nimbus 전체 MAU

문제는 모델 정확도가 아니라 의사결정 대기열입니다.

회사 전체: 1%p = \$4M/년

데이터 찾기 → 실험 비교 → 초안 → 승인 → 제품 반영이 팀과 도구 사이에서 끊어질 때, 매주 기회비용이 누적됩니다.

SEG-0000214에서 \$524.2K 위험과 \$721.3K 기회를 확인했습니다

420K MAU · Gen-Z / Android · 3주 전 대비 전환율 -1.3%p

현재 전환율

2.9%

3주 전 4.2%

위험 매출

\$524.2K

이 세그먼트 범위

추천 효과

+1.80%p

25% 제한 롤아웃

예상 순가치

\$721.3K

비용 \$5K 반영

EXP-0000009

+2.25%p · 유사 Android Gen-Z 실험

세 가지 후보 비교

가치 · 전환 효과 · 재사용 가능성

검증된 변형 출시

사람 승인 전에는 실행 없음

세 빌드가 하나의 감사 가능한 제품이 됩니다

governed data → Lakebase → app → Unity AI Gateway



동일한 `decision_id`가 검색 근거, AI 초안, 승인자, 커밋 시각을 연결합니다.

Delta 원본은 읽기 전용 · 앱은 `feature_decisions_app`만 씁니다

Ask → Decide → Ship

01

ASK

SEG-0000214의 하락 원인과 근거를 찾습니다

02

DECIDE

AI 초안을 보고 Sofia가 25% 롤아웃을 승인합니다

03


SHIP

같은 ID로 Lakebase에 커밋하고 비용을 확인합니다

앱: nimbus-growth-desk · 대시보드: 동일 Gateway URL

검색·승인·커밋이 하나의 결정 체인이 됩니다

사람의 판단은 AI의 생성 결과와 분리되어 명시적으로 기록됩니다.



decision_id 6c8... · proposed → approved → committed · append-only audit_trail

AI 비용은 보이고, 귀속되고, 멈춥니다

실제 Gateway 사용량 · 명시 단가 추정치 · 차단 결과를 같은 페이지에서 확인합니다.

추정 토큰 비용

\$0.0976

입력 \$0.15/M · 출력 \$0.60/M

요청 / 토큰

55 / 414.6K

두 Gateway 합계

403 차단

3

status_code + request_id

알림 / 하드 스톱

\$0.03 / \$0.05

데모 검증 임계값

보인다

시간별 비용 · 모델별 토큰
실제 외부 spend 없으면 NULL

귀속된다

request_tags['application']
requester · request_id

멈춘다

경고 \$0.03
하드 스톱 \$0.05 · 403

하나의 플랫폼과 하나의 AI 비용 제어면

데이터, 운영 상태, AI 호출을 별도 증거 체계로 다시 붙일 필요가 없습니다.

01

하나의 데이터 정의

Unity Catalog

세그먼트·실험·추천의 출처와 접근 권한을 통합

02

하나의 운영 상태

Lakebase

저지연 검색과 승인·커밋 트랜잭션을 같은 제품에

03

하나의 앱 표면

Databricks Apps

로그인 사용자, AI 결과, 사람 승인, 감사 이력

04

하나의 AI 제어면


Unity AI Gateway

비용, 귀속, 정책, 예산을 모델과 도구 전반에

RECOMMENDATION

25% 롤아웃, 제한된 AI 비용, 일 단위 실험 루프

큰 약속보다 작은 범위·짧은 피드백·명확한 중단 조건으로 시작합니다.



성공 기준: 전환 회복 + 비용 임계값 내 운영 + 모든 결정의 감사 가능성

ROI 산식과 범위

회사 전체 매크로 가치와 세그먼트 의사결정 가치를 분리합니다.

회사 전체

$\$400M \times 1\%p = \$4M/\text{년}$

SEG-0000214

모델 총가치 - 실행 비용 = \$721.3K 순가치


예상 순가치 = 예상 전환 증가 $\times$ 세그먼트 트래픽 $\times$ 주문가치 $\times$ 관측기간
- 실험·엔지니어링·운영 비용(\$5K)

주의: +2.25%p는 EXP-0000009 관측값, +1.80%p는 SEG-0000214 추천 예측값입니다.

대시보드의 \$0.03/\$0.05는 라이브 데모에서 검증한 AI 예산 임계값이며 연간 비용 상한이 아닙니다.

기술 아키텍처

읽기 경로, 쓰기 경로, AI 호출 경로를 분리하고 decision_id로 연결합니다.



`decision_id · assist_run_id · request_id`

데이터 읽기/쓰기 경계

동기화 테이블은 읽기 전용이며 앱은 단 하나의 운영 테이블만 변경합니다.

경로	대상	권한	증거
READ	nimbus_serving.segment_positions / experiments	SELECT only	source_kind = Build 1 continuous sync
SEARCH	app.search_experiments	READ ONLY + BM25	execution_plan에 index scan
WRITE	app.feature_decisions_app	INSERT / 상태 전이	proposed → approved → committed
RESET	SEG-0000214 decision rows only	제한 DELETE	confirm=true · synced sources unchanged

승인 전 커밋은 409로 거부 · 다른 segment_id 초기화는 400으로 거부

Gateway 통제와 비용 해석

비용 추정, 귀속, 차단, 실제 외부 spend를 각각 별도 필드로 취급합니다.

통제	구현	표시 원칙
비용 추정	$\text{input} \times \$0.15/\text{M} + \text{output} \times \$0.60/\text{M}$	추정치로 명시
귀속	<code>request_tags['application'] + requester + request_id</code>	요청 단위 추적
예산	<code>\$0.03 alert / \$0.05 hard stop</code>	데모 임계값
차단	<code>status_code = 403</code>	현재 3건 관측
실제 spend	<code>external_model_spend.usage_quantity</code>	행 없으면 NULL, 0 아님

발표에서는 설정 과정을 보여주지 않고 “보임 · 귀속 · 제한”의 결과만 보여줍니다.

예상 반론과 짧은 답변

정확성·승인·비용·락인·확장성 질문에 증거로 답합니다.

“AI가 틀리면?”

—— AI는 proposed 초안까지만. 실험 근거와 세 후보를 사람이 검토합니다.

“승인을 우회할 수 있나?”

—— proposed → committed는 상태 머신에서 거부되고 approved_by가 필수입니다.

“비용이 폭증하면?”

—— request 단위 귀속, \$0.03 알림, \$0.05 하드 스톱, 403 증거가 있습니다.

“실제 청구액이 0인가?”

—— 아닙니다. 외부 spend 행이 없으면 NULL/미제공이며 추정치와 분리합니다.

“다른 세그먼트로 확장?”

—— 동일 계약으로 segment_id만 바뀌되 초기화는 데모 세그먼트에만 제한합니다.